Sprawozdanie KM3: finalne rozwiązanie, ocena jakości i XAI

Oct 31, 2026 · @Bartek

1. Wprowadzenie

W KM2 wybrałem finalny model według reguły ustalonej w KM1: pretrenowany ResNet18 z augmentacją odpornościową A2. W ostatnim etapie zostały mi trzy rzeczy, które zamykają projekt:

1. **uczciwa ocena końcowa** na zbiorze testowym, który do tej pory leżał nietknięty,
2. **warstwa wyjaśnialności (XAI)**, która pokazuje, na co model patrzy, gdzie się myli i kiedy można mu ufać,
3. **aplikacja**, w której to wszystko widać na żywo.

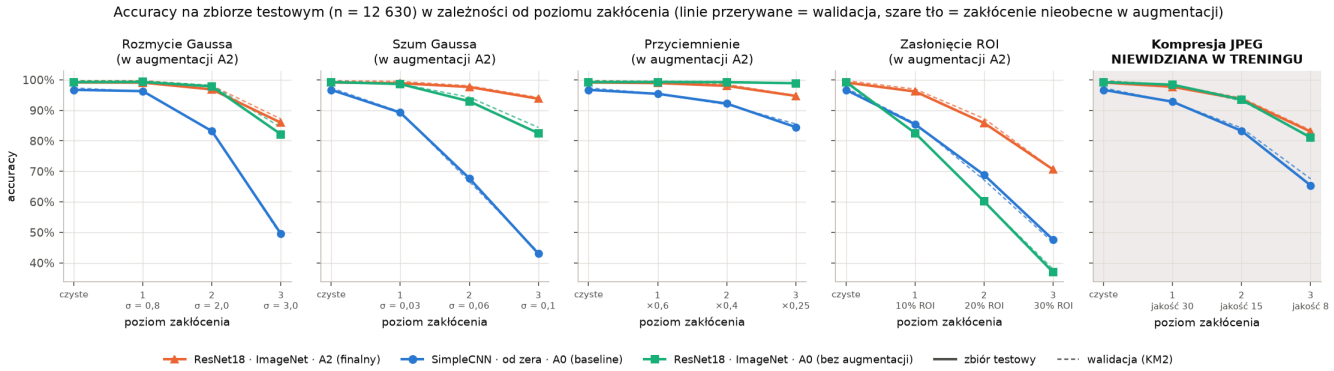
Na teście oceniłem trzy modele: finalny, baseline (SimpleCNN bez augmentacji) oraz pretrenowany ResNet18 bez augmentacji jako punkt odniesienia, żeby sprawdzić, czy efekt augmentacji utrzymuje się na nowych danych. Na podstawie testu nie podejmowałem już żadnych decyzji. Wszystkie progi i wybory zapadły wcześniej, na walidacji, a test służy wyłącznie do raportowania.

Czasy predykcji podaję za pomiarami z KM2, wykonanymi w jednej sesji na bezczynnym komputerze. Model się od tamtej pory nie zmienił, a podczas obliczeń w KM3 komputer był obciążony innymi programami, więc tamte pomiary nie byłyby wiarygodne.

2. Ocena końcowa na zbiorze testowym

Zbiór testowy (12 630 zdjęć) użyłem jednorazowo, z tymi samymi metrykami i zakłóceniami co na walidacji.

Model	macro-F1 walidacja	macro-F1 test	Accuracy test	mCA walidacja	mCA test
ResNet18, ImageNet, A2 (finalny)	99,69%	**98,44%**	99,13%	93,35%	**92,72%**
ResNet18, ImageNet, A0 (bez augmentacji)	99,50%	99,00%	99,26%	87,36%	86,89%
SimpleCNN, A0 (baseline)	95,25%	94,64%	96,72%	76,33%	76,30%



Rys. 1. Accuracy na zbiorze testowym w zależności od poziomu zakłócenia dla trzech modeli. Linie przerywane to wyniki z walidacji, szare tło oznacza zakłócenie nieobecne w augmentacji.

2.1. Główny wniosek się potwierdził

Najważniejsze dla mnie było, czy przewaga w odporności nie była artefaktem walidacji. Nie była: na teście finalny model ma mCA o 5,8 p.p. wyższe niż ten sam ResNet18 bez augmentacji, praktycznie tyle samo co na walidacji (6,0 p.p.). Linie przerywane na rys. 1 niemal pokrywają się z ciągłymi, więc zachowanie modeli przy zakłóceniach jest stabilne między zbiorami.

Zakłócenie (średnia z 3 poziomów)	Finalny (A2)	ResNet18 A0	Baseline
Rozmycie Gaussa	94,0%	93,1%	76,3%
Szum Gaussa	96,8%	91,4%	66,7%
Przyciemnienie	97,2%	99,1%	90,7%
Zasłonięcie	84,2%	59,9%	67,3%
Kompresja JPEG (niewidziana)	91,5%	91,0%	80,5%

Największa różnica jest przy zasłonięciu: na najsilniejszym poziomie finalny model rozpoznaje 84,2% znaków, a ResNet bez augmentacji tylko 59,9%, czyli mniej niż prosty baseline. Przy JPEG wszystkie trzy linie na rys. 1 dalej prawie się pokrywają, co potwierdza wniosek z KM2, że odporność nie przenosi się na zakłócenie niewidziane w treningu. Tak jak na walidacji, A2 lekko szkodzi przy przyciemnieniu (97,2% wobec 99,1%).

2.2. Uczciwa niespodzianka na czystych danych

Na czystym teście lepszy okazał się ResNet18 **bez** augmentacji: 99,00% macro-F1 wobec 98,44% dla finalnego modelu. Na walidacji było odwrotnie. Koszt augmentacji A2 na czystych danych wynosi więc w rzeczywistości około 0,6 p.p., a nie zero, jak wychodziło

na walidacji. Nadal mieści się to w progu 1 p.p. z hipotezy H2, ale warto to wyraźnie zaznaczyć.

2.3. Różnica między walidacją a testem

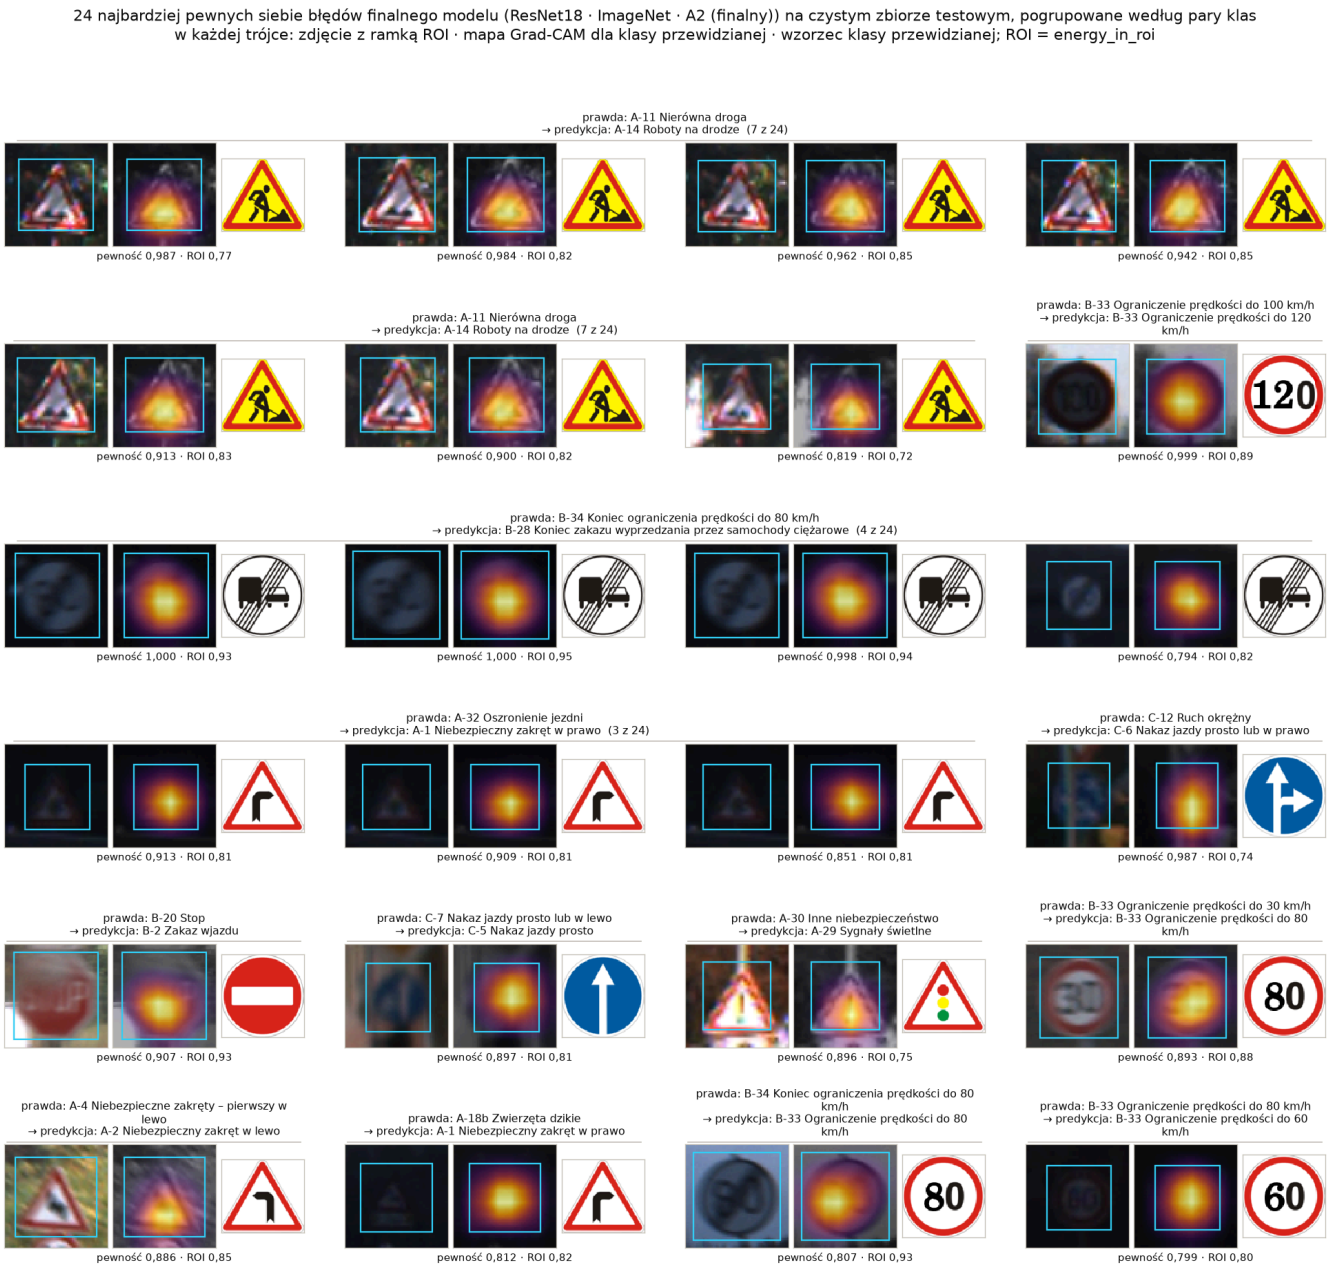
Finalny model stracił na teście najwięcej: 1,25 p.p. macro-F1, podczas gdy pozostałe około 0,5 do 0,6 p.p. To spodziewany efekt wyboru. Spośród 11 wariantów i wielu epok wybrałem ten, któremu na walidacji poszło najlepiej, więc część jego przewagi była szczęściem. W KM2 zwróciłem uwagę, że ten przebieg osiągnął najlepszy wynik już w 4. epoce przy mocno skaczącej walidacji, i test to potwierdza. Odporność (mCA) prawie nie spadła, bo nie ona decydowała o wyborze najlepszej epoki.

3. Analiza błędów

Na czystym teście finalny model pomylił się 110 razy na 12 630 zdjęć. W KM1 obstawiałem, że najwięcej pomyłek będzie między ograniczeniami prędkości, które różnią się tylko cyframi. Okazało się, że byłem w błędzie: ograniczenia prędkości są rozpoznawane niemal bezbłędnie, a kłopot sprawiają trójkątne znaki ostrzegawcze.

Prawdziwy znak	Rozpoznany jako	Liczba	Udział w błędach
A-11 Nierówna droga	A-14 Roboty na drodze	19	17%
A-4 Niebezpieczne zakręty, pierwszy w lewo	A-6a Skrzyżowanie z drogą podporządkowaną	14	13%
A-18b Zwierzęta dzikie	A-1 Niebezpieczny zakręt w prawo	9	8%
A-32 Oszronienie jezdni	A-1 Niebezpieczny zakręt w prawo	8	7%
A-30 Inne niebezpieczeństwo	A-16 Przejście dla pieszych	7	6%
B-34 Koniec ograniczenia do 80 km/h	B-33 Ograniczenie do 80 km/h	6	5%

Wszystkie najsłabsze klasy to znaki ostrzegawcze, a najniższe F1 mają „Niebezpieczne zakręty, pierwszy w lewo” (0,89) i „Nierówna droga” (0,90). Wyjaśnienie jest dość proste. Wszystkie te znaki mają identyczny kształt i kolor, a różni je tylko mały piktogram w środku, który przy wejściu 64×64 px ma kilkanaście pikseli. Przy ograniczeniach prędkości cyfry zajmują dużo większą część znaku.



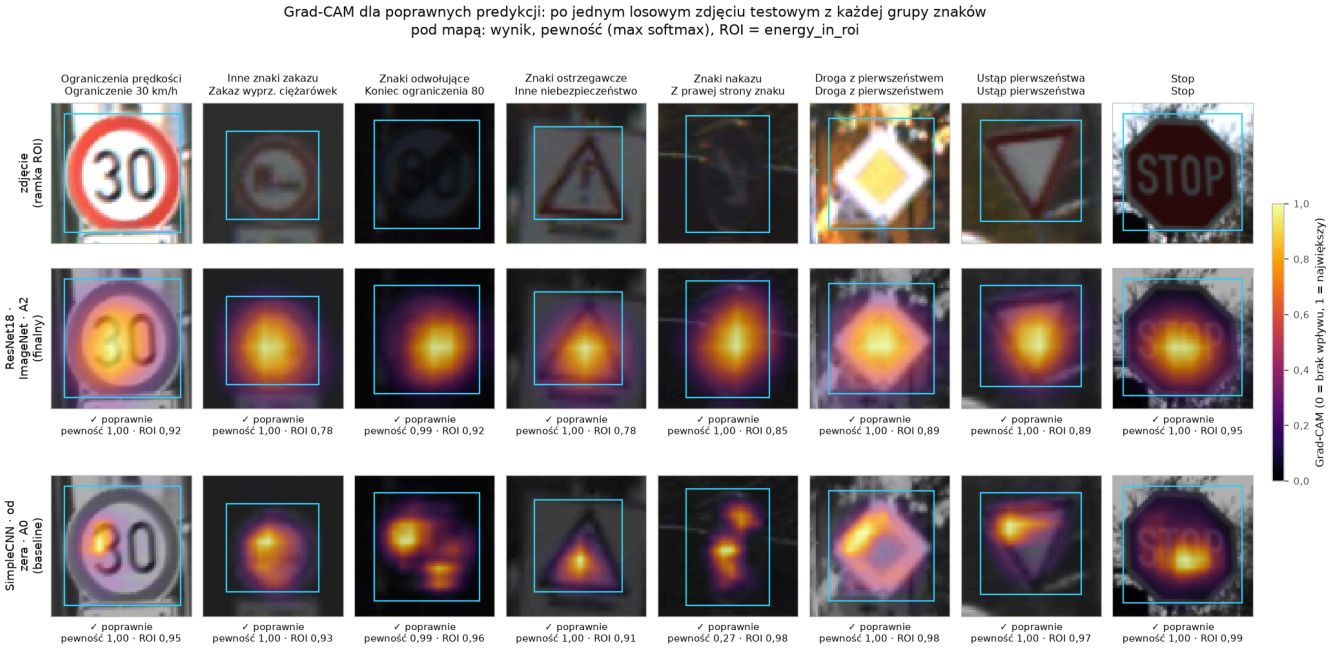
Rys. 2. 24 najbardziej pewne siebie błędy finalnego modelu na czystym teście. W każdej trójce: zdjęcie z ramką ROI, mapa Grad-CAM i wzorzec klasy, którą wskazał model.

Galeria pokazuje dwie rzeczy, których nie widać w samych liczbach:

- **Błędy są skupione na kilku fizycznych znakach.** Zbiór testowy też składa się z klatek nagrań, więc siedem błędów „nierówna droga → roboty na drodze" to w praktyce kolejne klatki jednego znaku. 110 błędów nie oznacza więc 110 różnych sytuacji.
- **Część błędów dotyczy zdjęć praktycznie nieczytelnych.** Bardzo ciemne znaki „koniec ograniczenia do 80 km/h" model rozpoznał jako „koniec zakazu wyprzedzania przez samochody ciężarowe" z pewnością bliską 100%. To najgroźniejszy typ błędu, bo nie wyłapie go żaden próg pewności (rozdział 5).

4. XAI: na co patrzy model

Do wyjaśniania decyzji użyłem metody Grad-CAM [1]. Tworzy ona mapę ciepła pokazującą, które fragmenty zdjęcia najmocniej wpłynęły na wybraną klasę. Mapę liczę dla ostatniej warstwy konwolucyjnej: w ResNet18 ma ona rozdzielczość 8×8 (dzięki adaptacji opisanej w KM2, bez której miałaby tylko 2×2), a w SimpleCNN 16×16.



Rys. 3. Grad-CAM dla poprawnych predykcji, po jednym zdjęciu z każdej grupy znaków. Środkowy rząd to model finalny, dolny to baseline.

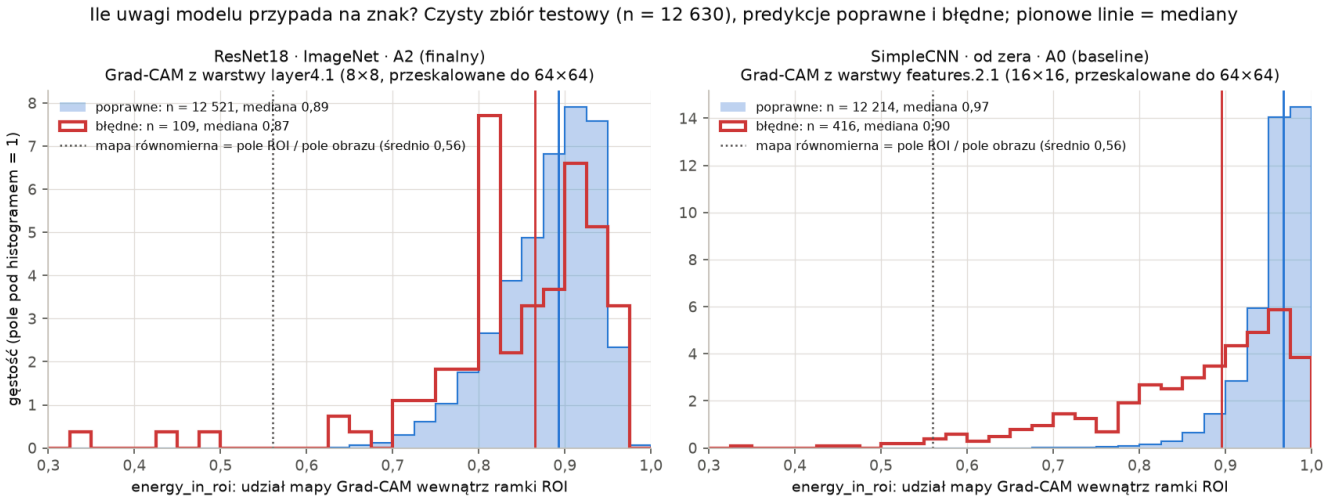
Na rys. 3 widać różnicę w „stylu patrzenia". Finalny model ma jedną, spójną plamę uwagi na środku znaku, tam gdzie jest piktogram albo liczba. Baseline często skupia się na pojedynczych fragmentach, np. na lewej cyfrze ograniczenia albo na krawędzi znaku „ustąp pierwszeństwa".

4.1. Ilościowo: ile uwagi przypada na znak

Żeby nie opierać się tylko na oglądaniu obrazków, wykorzystałem ramki ROI ze zbioru danych. Dla każdego zdjęcia policzyłem, jaka część mapy Grad-CAM leży wewnątrz ramki ze znakiem. Punktem odniesienia jest pole samej ramki: gdyby mapa była równomierna, wewnątrz ramki leżałoby średnio 56% uwagi.

Model	Predykcje poprawne	Predykcje błędne	Mapa równomierna
ResNet18 A2 (finalny), czysty test	88,1%	84,7%	56%

Model	Predykcje poprawne	Predykcje błędne	Mapa równomierna
SimpleCNN (baseline), czysty test	95,8%	86,0%	56%
SimpleCNN, szum poziomu 2	94,2%	71,4%	56%



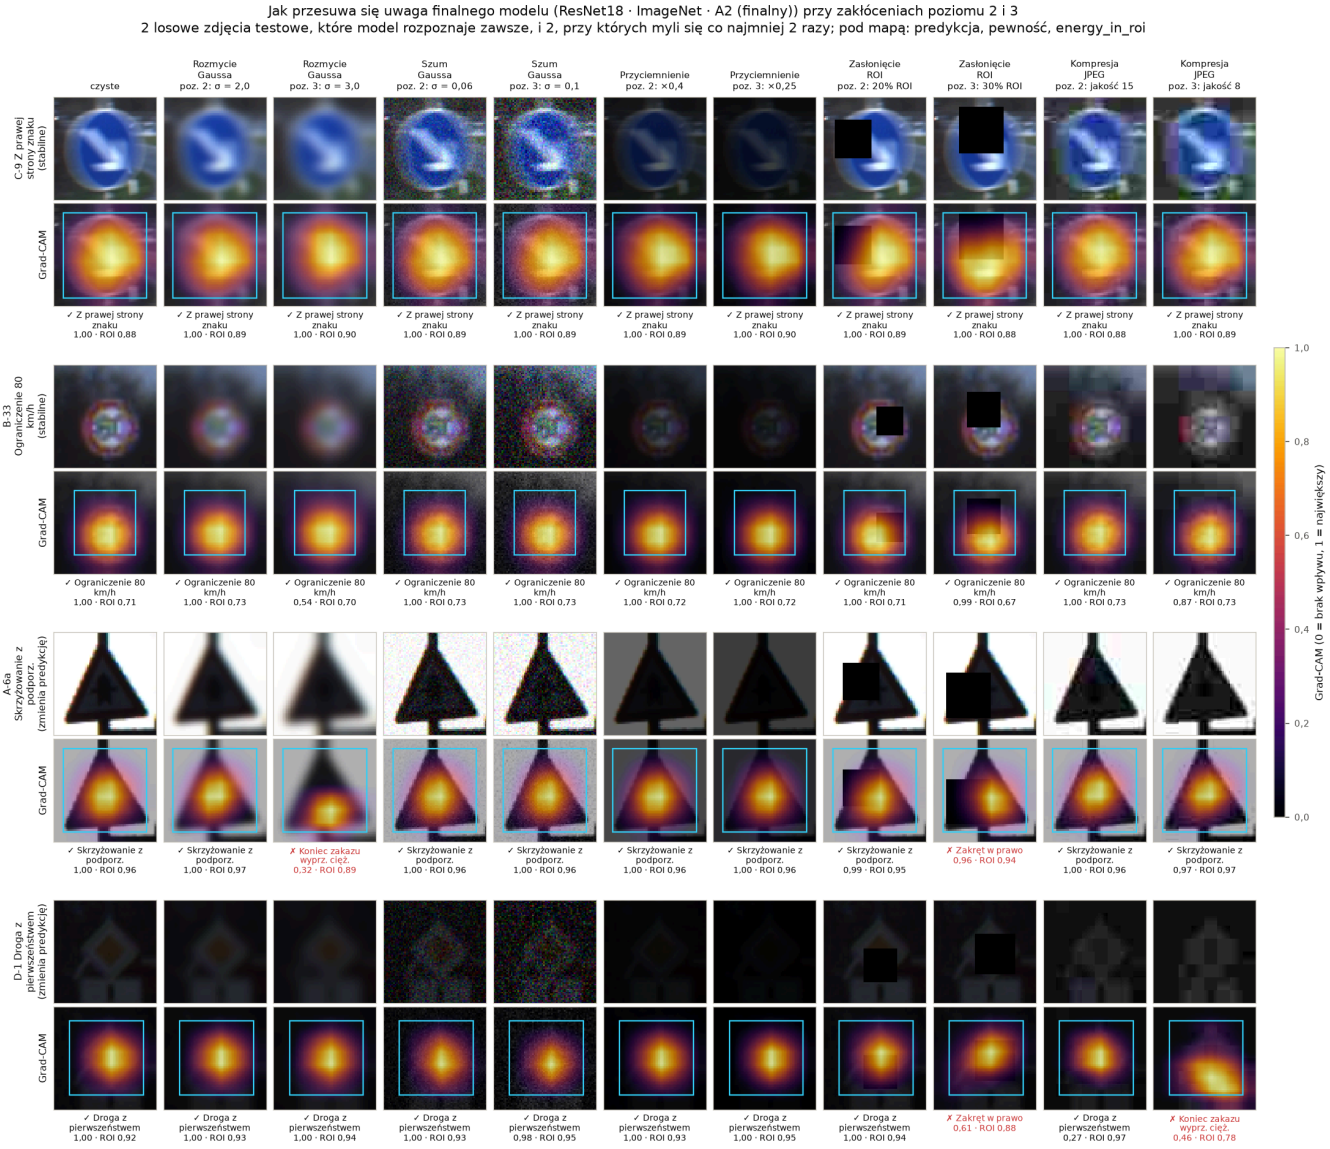
Rys. 4. Rozkład udziału mapy Grad-CAM wewnątrz ramki ROI dla predykcji poprawnych i błędnych na czystym teście.

Oba modele patrzą na znak, a nie na tło: udział uwagi w ramce jest wyraźnie wyższy niż 56%. Ciekawsze jest jednak porównanie trafień i pomyłek w obrębie jednego modelu:

- **Finalny model myli się, patrząc we właściwe miejsce.** Przy błędach udział uwagi w ramce jest prawie taki sam jak przy trafieniach (84,7% wobec 88,1%). Jego pomyłki nie wynikają z tego, że „zgubił" znak, tylko z tego, że nie rozróżnił podobnych piktogramów, co zgadza się z analizą błędów.
- **Baseline przy zakłóceniach gubi znak.** Na zaszumionych zdjęciach udział uwagi w ramce spada przy błędach do 71,4%, czyli model zaczyna reagować na szum w tle.

Dwa zastrzeżenia. Porównywanie wartości bezwzględnych między modelami nie jest do końca uczciwe, bo ostrzejsza mapa 16×16 baseline'u naturalnie mieści się w ramce lepiej niż mapa 8×8 ResNeta. Dlatego wnioski opieram na porównaniu trafień i błędów w obrębie jednego modelu. Po drugie, przy zasłonięciu finalny model kładzie około 22% mapy na czarnym prostokącie. Nie oznacza to, że „patrzy na zasłonięcie": mapa 8×8 to dość gruba plama na środku znaku, a prostokąt też leży na środku.

4.2. Jak uwaga przesuwa się przy zakłóceniach

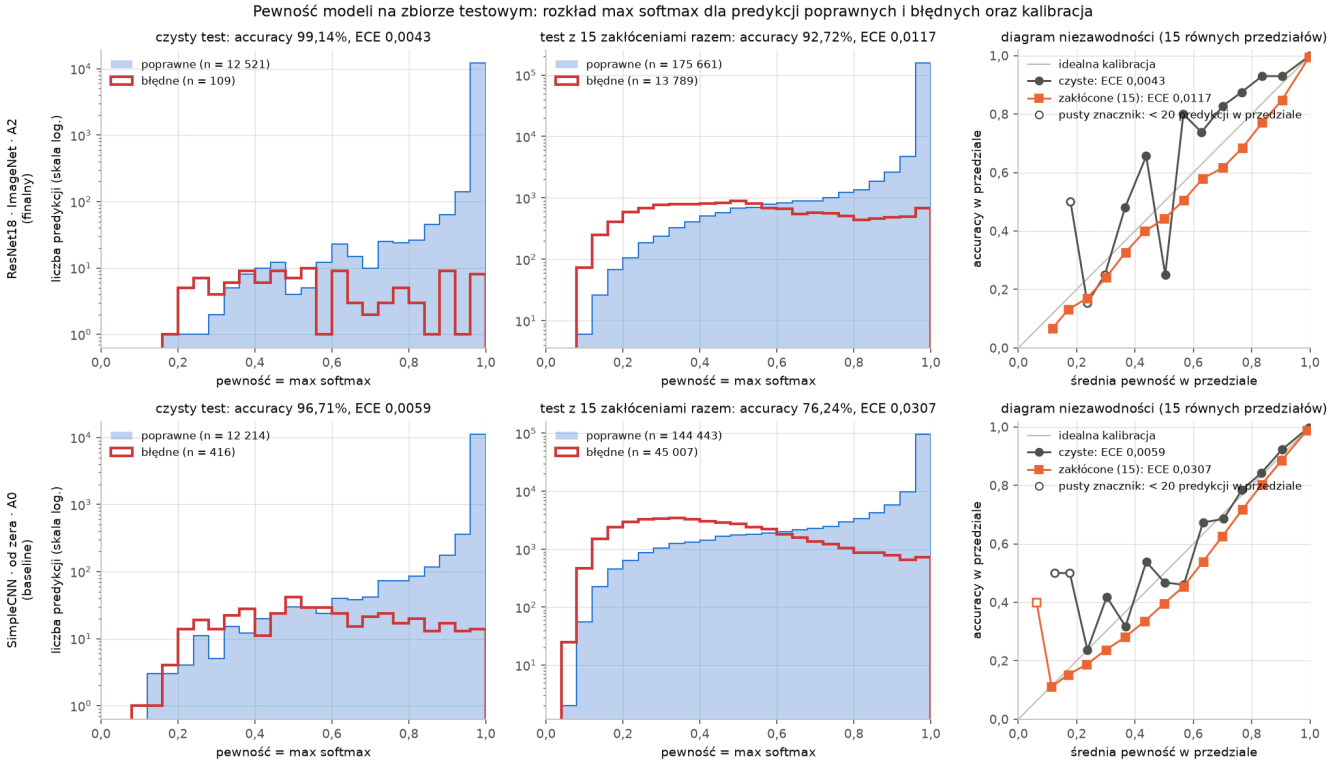


Rys. 5. Grad-CAM finalnego modelu dla czterech zdjęć testowych przy zakłóceniach poziomu 2 i 3. Dwa górne zdjęcia model rozpoznaje zawsze, dwa dolne przy niektórych zakłóceniach zmieniają predykcję.

Dla stabilnych zdjęć mapa wygląda niemal tak samo bez względu na zakłócenie, co dobrze świadczy o odporności. Przy zdjęciach, na których model zmienia zdanie, widać dwa scenariusze. Przy silnym rozmyciu i JPEG mapa ucieka z centrum znaku: na ciemnym znaku „droga z pierwszeństwem” po kompresji JPEG przesuwa się w róg obrazu i model się myli. Przy zasłonięciu mapa zostaje w miejscu, gdzie był piktogram, ale skoro go tam nie ma, model zgaduje na podstawie samego kształtu znaku.

5. Pewność modelu i próg odrzucania

W systemie, który ma wspierać kierowcę, ważne jest nie tylko to, jak często model ma rację, ale też czy „wie, kiedy nie wie". Jako miarę pewności przyjąłem najwyższe prawdopodobieństwo zwracane przez model (max softmax).

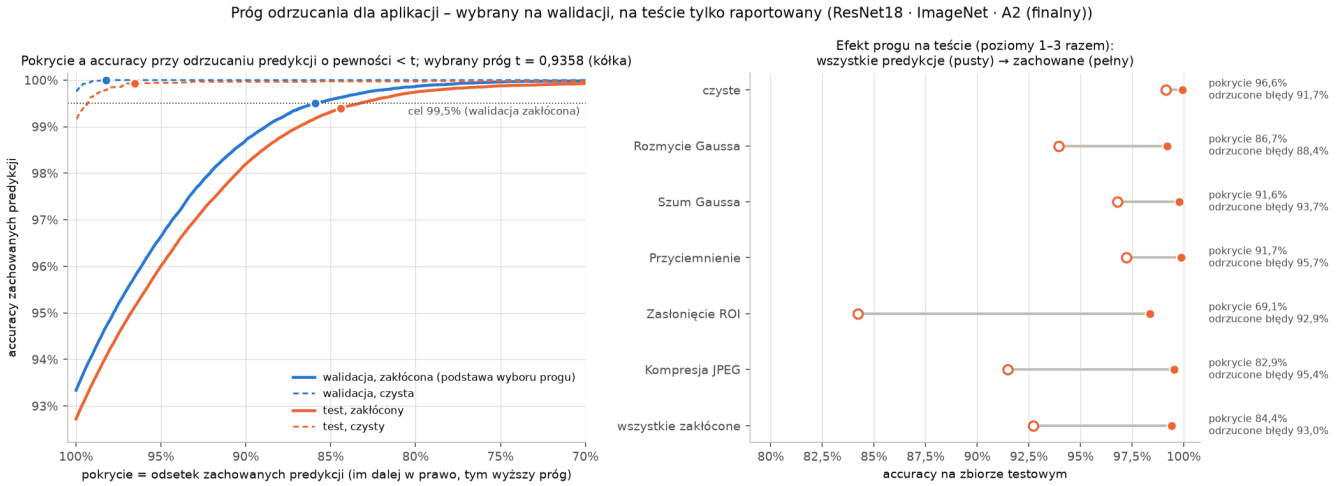


Rys. 6. Rozkład pewności dla predykcji poprawnych i błędnych oraz diagram niezawodności, dla finalnego modelu (góra) i baseline'u (dół).

Finalny model jest dobrze skalibrowany. Średni błąd kalibracji (ECE [2]) wynosi 0,43% na czystym teście i 1,17% na zakłóconym. Przy trafieniach jego średnia pewność to 99,2%, a przy błędach 56,1%, więc pewność rzeczywiście niesie informację o tym, czy wynikowi można ufać. Baseline jest skalibrowany słabiej, szczególnie na zakłóconych danych (ECE 3,07%).

5.1. Próg dla aplikacji

Na tej podstawie wyznaczyłem próg, poniżej którego aplikacja ostrzega, że model nie jest pewny. Próg wybrałem **wyłącznie na walidacji**: to najniższa pewność, przy której zachowane predykcje na zakłóconej walidacji mają co najmniej 99,5% trafień. Wyszło 0,936. Na teście tylko sprawdziłem, jak działa.



Rys. 7. Lewo: accuracy zachowanych predykcji w zależności od odsetka zachowanych predykcji. Prawo: efekt wybranego progu na teście dla każdego zakłócenia.

Zbiór testowy	Zachowane predykcje	Accuracy wszystkich	Accuracy zachowanych	Odrzucone błędy
Czysty	96,6%	99,14%	99,93%	91,7%
Zakłócony (15 wersji razem)	84,4%	92,72%	99,40%	93,0%
Zasłonięcie	69,1%	84,20%	98,40%	92,9%

Próg przeniósł się z walidacji na test bardzo dobrze: na zakłóconych danych zachowane predykcje mają 99,40% trafień przy celu 99,5%. Na czystych zdjęciach model odrzuca tylko 3,4% predykcji, a wyłapuje przy tym ponad 90% swoich błędów. Najwięcej odrzuca przy zasłonięciu (31%), co jest dokładnie tym zachowaniem, jakiego bym chciał: im trudniejsze warunki, tym częściej system przyznaje się do niepewności, zamiast zgadywać.

Słabym punktem są błędy popełnione z bardzo wysoką pewnością. Na czystym teście 3,7% błędów ma pewność powyżej 99%, więc żaden rozsądny próg ich nie zatrzyma.

6. Aplikacja

Całość zamknąłem w aplikacji webowej napisanej w Gradio (`app/app.py`), uruchamianej lokalnie poleceniem `python -m app.app`. Działa na karcie graficznej albo na samym procesorze, gdzie rozpoznanie jednego zdjęcia razem z mapą Grad-CAM trwa około 0,1 s.

Sprawdziłem, że aplikacja pokazuje dokładnie ten model, który oceniłem: jej predykcje na całym zbiorze testowym zgadzają się z wynikami ewaluacji dla 12 629 z 12 630 zdjęć. Jedyna różnica dotyczy zdjęcia, na którym dwie klasy mają praktycznie równe

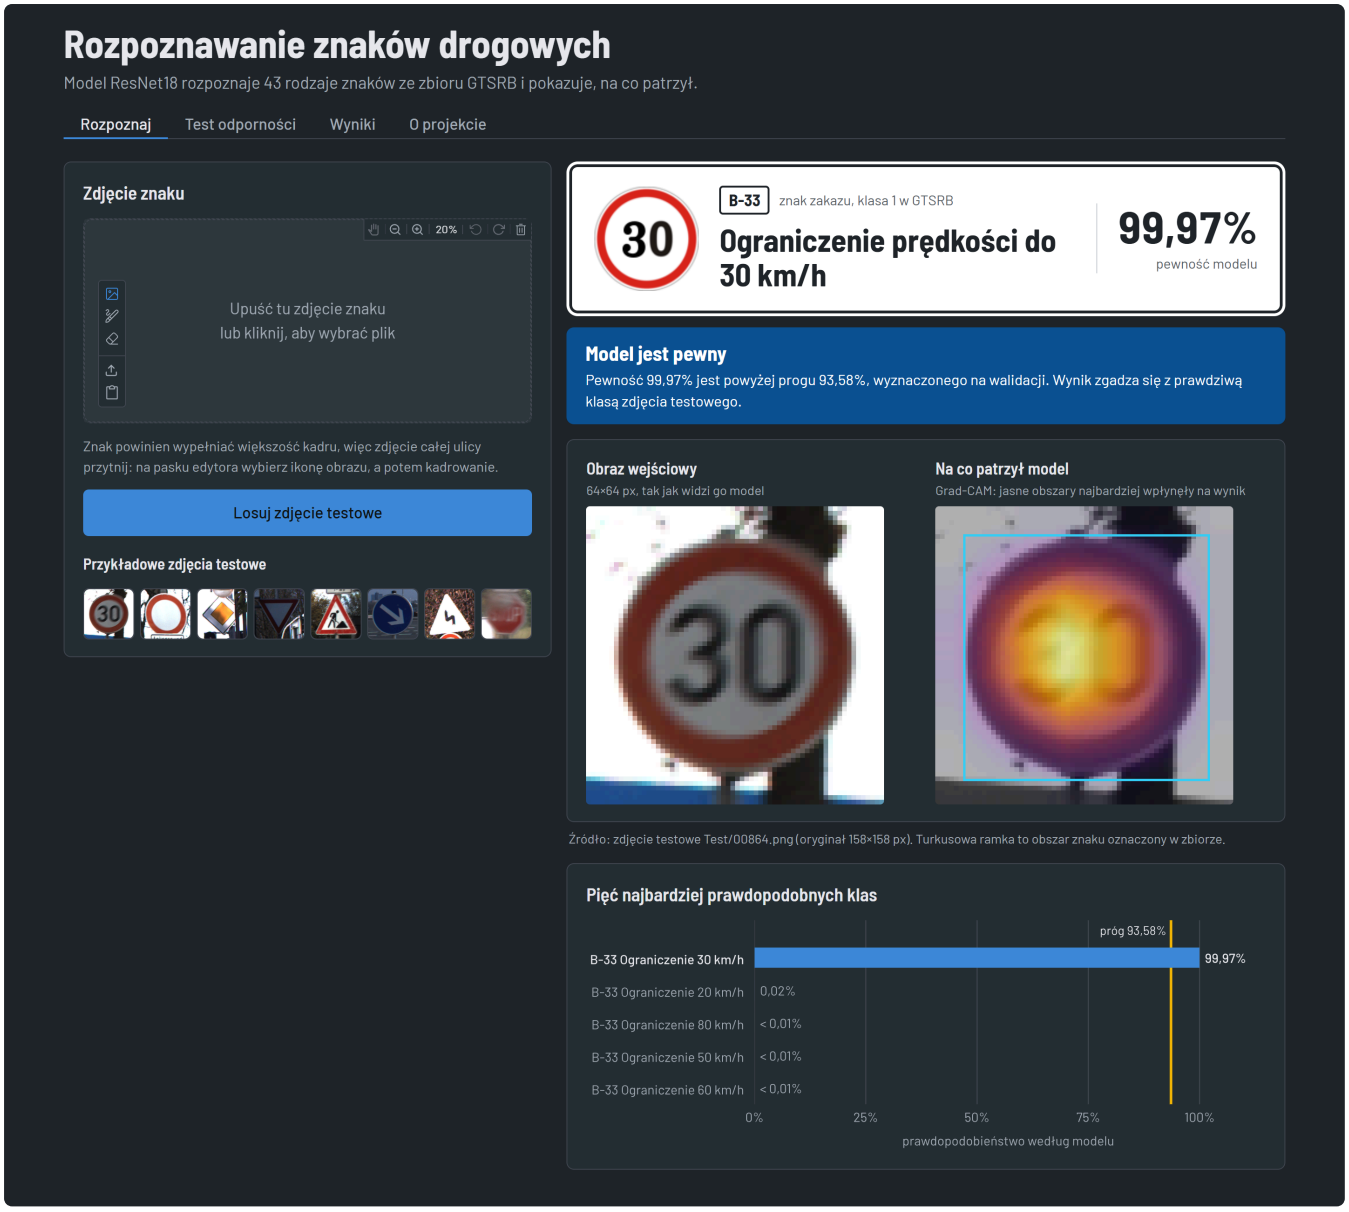
prawdopodobieństwo (28,9% i 28,5%), więc o wyniku decydują drobne różnice numeryczne. Zakłócone obrazy w aplikacji są identyczne z tymi, na których liczyłem wyniki.

6.1. Wygląd

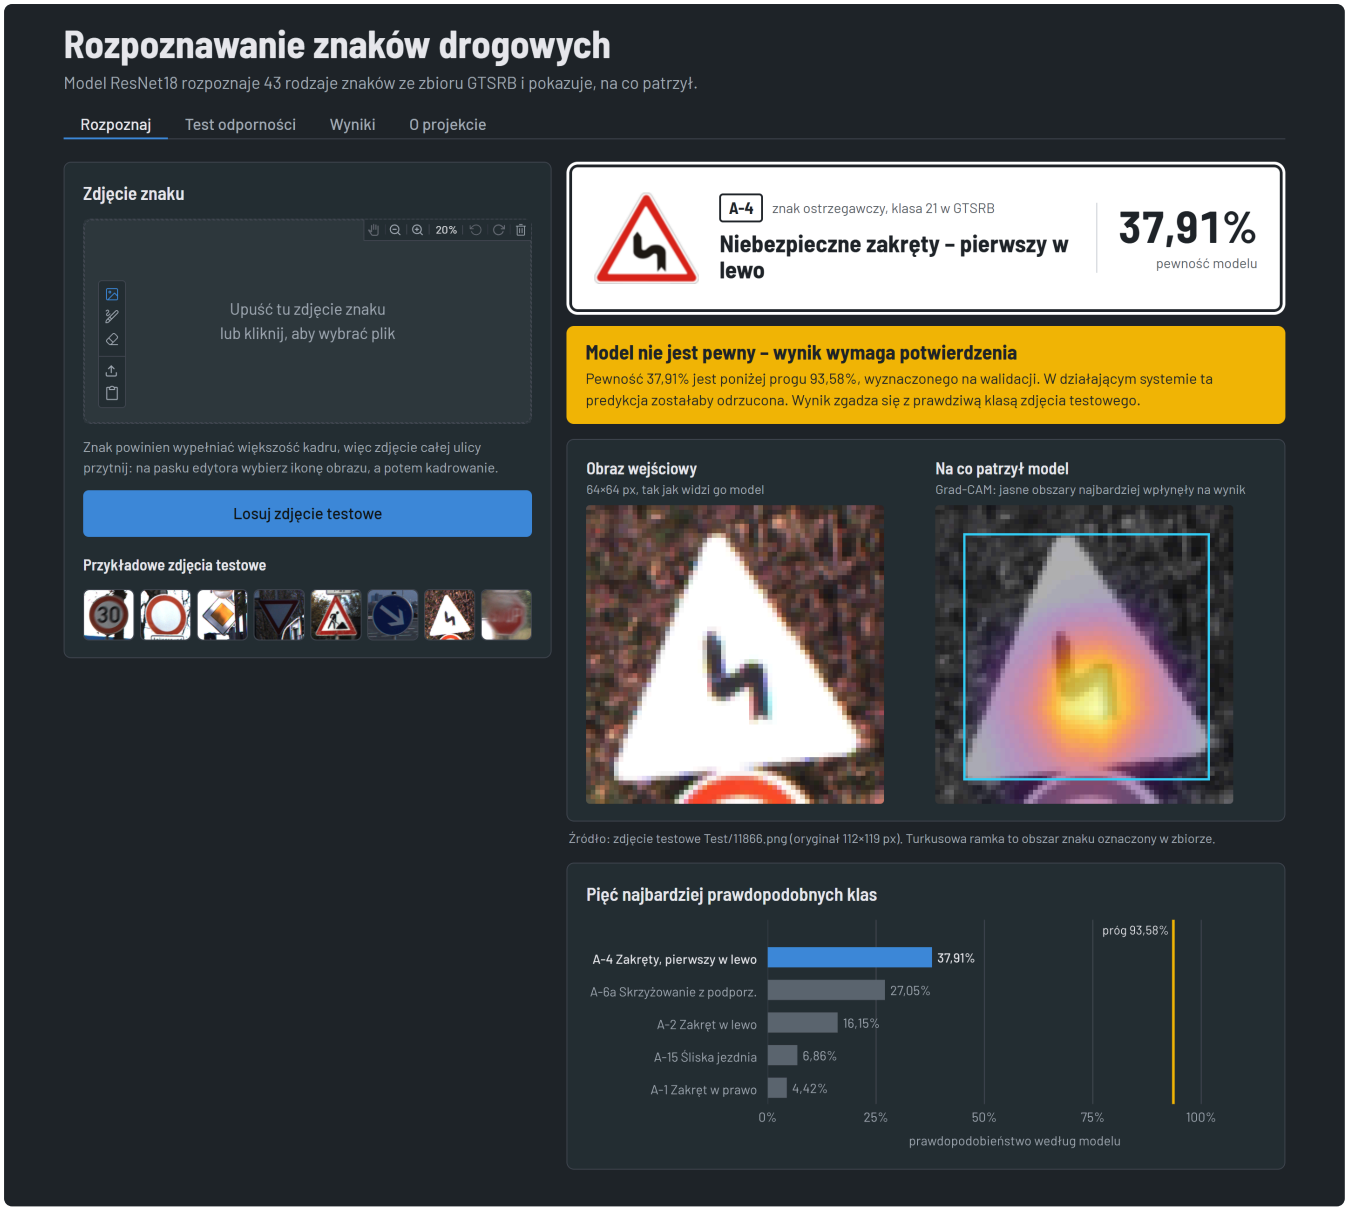
Pierwsza wersja interfejsu wyglądała jak domyślny szablon, więc przeprojektowałem ją pod temat projektu. Interfejs używa kroju Barlow, opartego na DIN 1451, czyli kroju z niemieckich znaków drogowych, z których pochodzi zbiór. Ciemne tło nawiązuje do drogi nocą, a jedynym jasnym elementem jest biała „tabliczka" z wynikiem, jak znak w świetle reflektorów. Kolory pasków stanu pochodzą z oznakowania i mają stałe znaczenie: niebieski to wynik pewny, żółty to niepewność, czerwony to pomyłka.

6.2. Zakładka „Rozpoznaj"

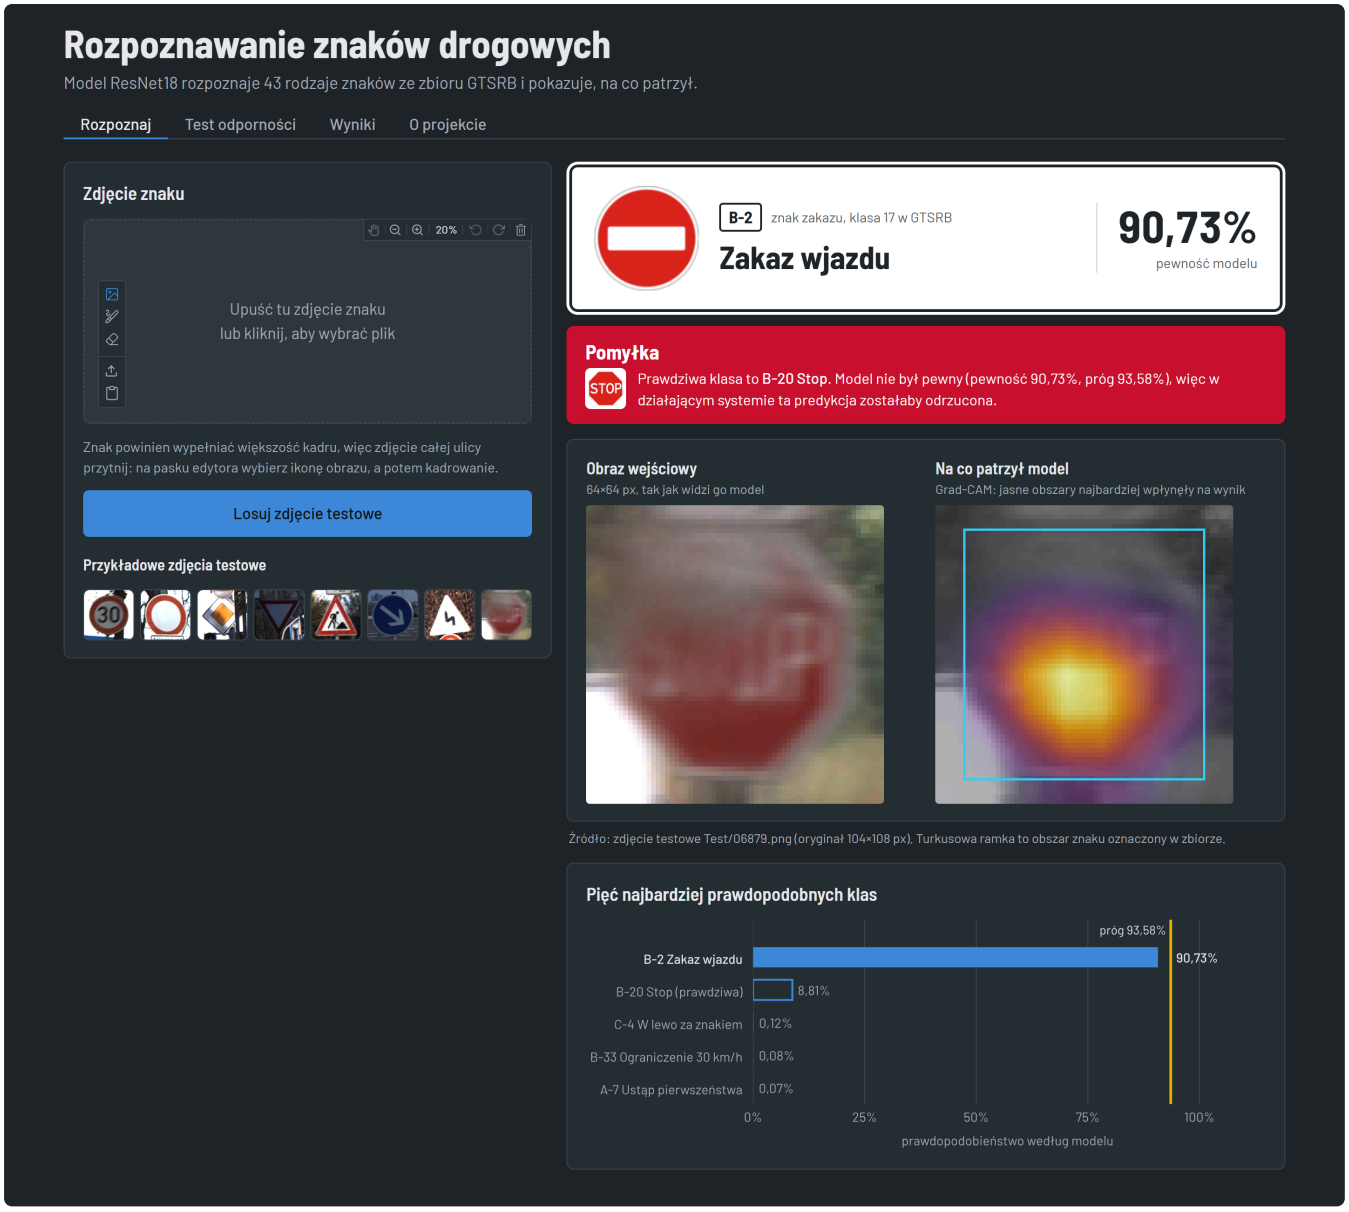
Można wgrać własne zdjęcie i przyciąć je do znaku, wylosować zdjęcie testowe albo kliknąć jedną z ośmiu miniatur. Aplikacja pokazuje rozpoznany znak z polską nazwą i kodem, pewność, mapę Grad-CAM, pięć najbardziej prawdopodobnych klas na tle progu oraz, dla zdjęć testowych, prawdziwą klasę.



Rys. 8. Pewna i poprawna predykcja: ograniczenie prędkości do 30 km/h, pewność 99,97%.



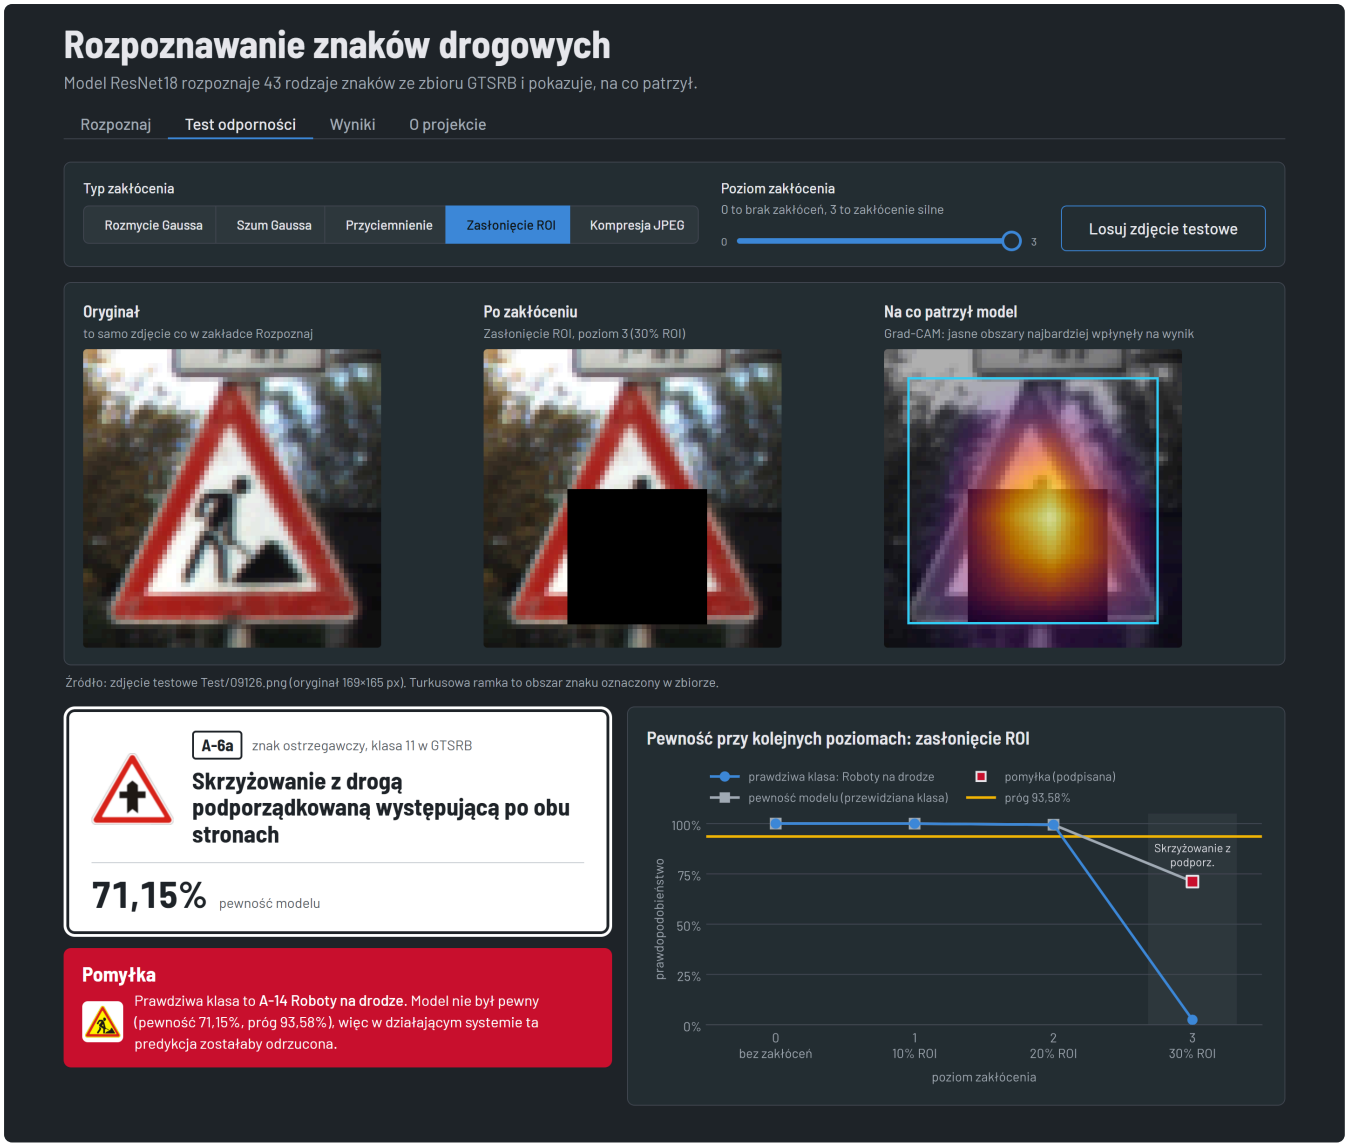
Rys. 9. Wynik poprawny, ale z pewnością 37,9%: żółty pasek informuje, że w działającym systemie ta predykcja zostałaby odrzucona.



Rys. 10. Pomyłka na rozmytym zdjęciu: STOP rozpoznany jako „Zakaz wjazdu”. Pewność 90,7% jest poniżej progu, a prawdziwa klasa jest druga na liście.

6.3. Zakładka „Test odporności”

To samo zdjęcie można poddać jednemu z pięciu zakłóceń i suwakiem zmieniać jego siłę. Na żywo widać zakłócony obraz, nową predykcję, mapę uwagi i wykres pewności w funkcji poziomu zakłócenia.



Rys. 11. „Roboty na drodze” przy zasłonięciu 30% ramki: model zmienia odpowiedź na „Skrzyżowanie z drogą podporządkowaną”, a pewność prawdziwej klasy spada z niemal 100% do zera.

Ten przykład dobrze pokazuje mechanizm opisany w rozdziale 4.2: mapa uwagi świeci dokładnie tam, gdzie był piktogram robotnika. Model szuka kluczowego fragmentu, a gdy go nie znajduje, wybiera inny znak o tym samym kształcie.

6.4. Zakładki „Wyniki” i „O projekcie”

„Wyniki” zbierają tabele i wykresy z KM2 i KM3, poprzedzone krótkim akapitem wniosków, w którym liczby są czytane bezpośrednio z plików z wynikami. „O projekcie” zawiera krótki opis, link do repozytorium i ograniczenia modelu.

Rozpoznawanie znaków drogowych

Model ResNet18 rozpoznaje 43 rodzaje znaków ze zbioru GTSRB i pokazuje, na co patrzył.

Rozpoznaj | Test odporności | **Wyniki** | O projekcie

Model finalny, ResNet18 z wagami ImageNet i augmentacją odpornościową A2, rozpoznaje poprawnie 99,1% zdjęć testowych, a zdjęć zakłóconych średnio 92,7%. Własny baseline SimpleCNN osiąga odpowiednio 96,7% i 76,3%, a ta sama sieć ResNet18 bez augmentacji 86,9% na zdjęciach zakłóconych, więc odporność daje głównie augmentacja. Najtrudniejsze pozostaje zakłócenie „zasłonięcie ROI" (średnio 84,2% na trzech poziomach). Grad-CAM pokazuje, że model patrzy na znak, a próg pewności 93,58% odrzuca 3,4% zdjęć testowych i zostawia predykcje poprawne w 99,93%.

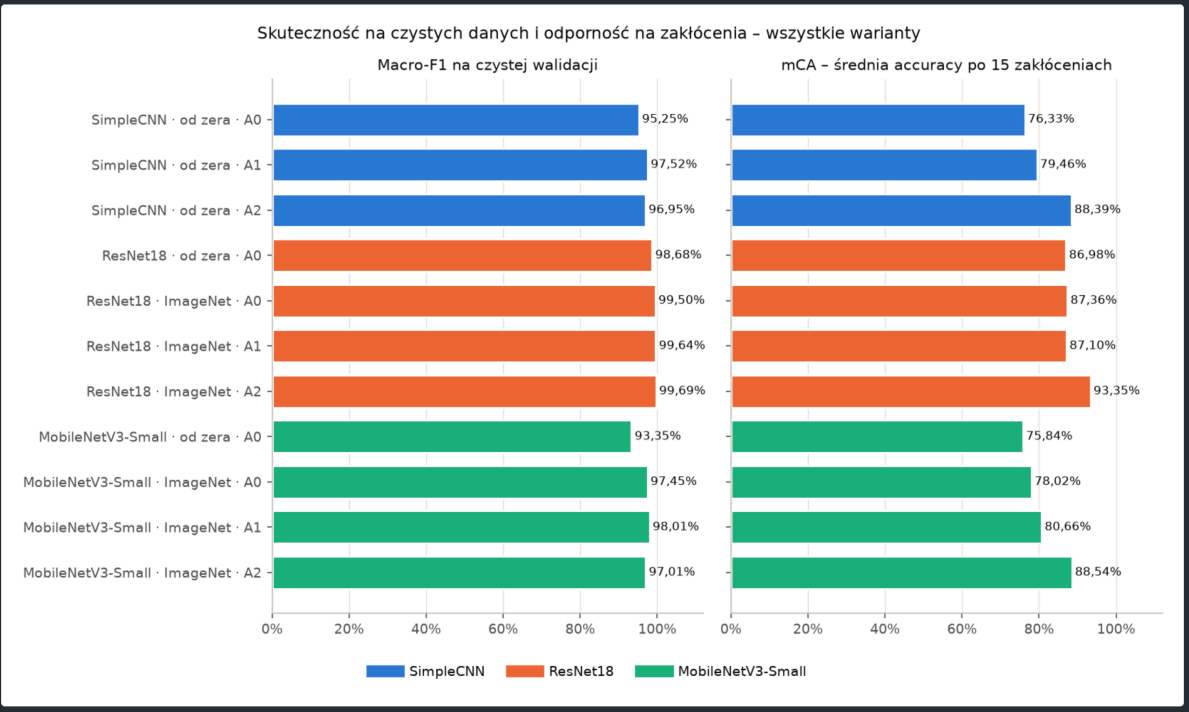
Porównanie wariantów na walidacji

Wszystkie wytrenowane warianty, oceniane na walidacji (serie zdjęć wydzielone ze zbioru treningowego). mCA to średnia accuracy po 5 zakłóceniach i 3 poziomach, względny spadek to (accuracy − mCA) / accuracy, CPU to mediana czasu predykcji jednego zdjęcia. Wyróżniony wiersz to model finalny, używany w aplikacji.

Model	Wagi startowe	Augmentacja	Etap	Seed	Accuracy	Macro-F1	mCA	Wzgl. spadek	Parametry	CPU [ms]	Najlepsza epoka
SimpleCNN	od zera	A0	E1	42	97,35%	95,25%	76,33%	21,6%	0,29 mln	3,5	16 z 20
SimpleCNN	od zera	A1	E2	42	98,38%	97,52%	79,46%	19,2%	0,29 mln	3,5	19 z 20
SimpleCNN	od zera	A2	E2	42	98,16%	96,95%	88,39%	9,9%	0,29 mln	3,4	19 z 20
ResNet18	od zera	A0	E1	42	99,25%	98,68%	86,98%	12,4%	11,20 mln	26,8	20 z 20
ResNet18	ImageNet	A0	E1	42	99,67%	99,50%	87,36%	12,4%	11,20 mln	27,0	15 z 20
ResNet18	ImageNet	A1	E2	42	99,71%	99,64%	87,10%	12,6%	11,20 mln	27,2	19 z 20
ResNet18	**ImageNet**	**A2**	**E2**	**42**	**99,73%**	**99,69%**	**93,35%**	**6,4%**	**11,20 mln**	**27,1**	**4 z 9**
MobileNetV3-Small	od zera	A0	E1	42	95,64%	93,35%	75,84%	20,7%	1,56 mln	5,8	16 z 20
MobileNetV3-Small	ImageNet	A0	E1	42	98,30%	97,45%	78,02%	20,6%	1,56 mln	5,4	9 z 14
MobileNetV3-Small	ImageNet	A1	E2	42	98,69%	98,01%	80,66%	18,3%	1,56 mln	5,8	10 z 15
MobileNetV3-Small	ImageNet	A2	E2	42	98,23%	97,01%	88,54%	9,9%	1,56 mln	6,2	8 z 13
ResNet18	ImageNet	A2	E4	43	99,72%	99,69%	95,10%	4,6%	11,20 mln	27,6	11 z 16
ResNet18	ImageNet	A2	E4	44	99,90%	99,81%	96,43%	3,5%	11,20 mln	27,0	15 z 20

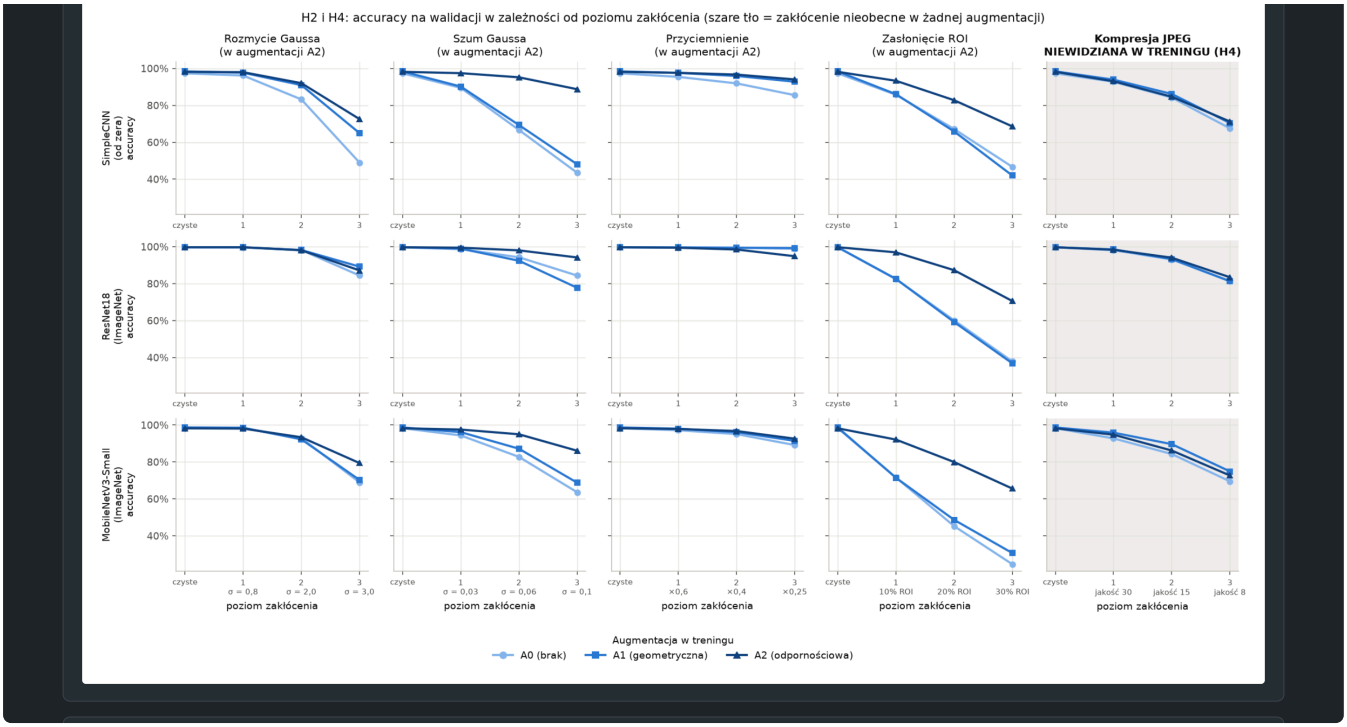
Skuteczność i odporność wszystkich wariantów

Macro-F1 na czystej walidacji i mCA. Na czystych danych różnice są niewielkie, w odporności duże: ResNet18 z wagami ImageNet i augmentacją A2 ma mCA 93,3%, baseline SimpleCNN bez augmentacji 76,3%.



Accuracy a poziom zakłócenia (H2, H4)

Augmentacje A0, A1 i A2 w każdej architekturze. A2 najmocniej pomaga przy szumie i zasłonięciu; przy kompresji JPEG, której nie było w treningu, zysk jest znacznie mniejszy.



Rys. 12. Zakładka „Wyniki": akapit wniosków, tabela wszystkich wariantów i wykresy porównawcze.

7. Mocne i słabe strony

7.1. Mocne strony

- **Wysoka skuteczność i odporność potwierdzona na niezależnych danych:** 99,1% accuracy na czystym teście i 92,7% średnio na zakłóconym, z przewagą w odporności takiej samej jak na walidacji.
- **Model wie, kiedy nie wie.** Jest dobrze skalibrowany, a próg wyznaczony na walidacji wyłapuje około 92% błędów, odrzucając tylko 3,4% czystych zdjęć.
- **Decyzje są wytłumaczalne.** Model patrzy na znak, a jego pomyłki mają sensowne wyjaśnienie: podobne piktogramy w małej rozdzielczości.
- **Rzetelna metodologia.** Podział po seriach bez wycieku, reguły wyboru ustalone przed treningami i zbiór testowy użyty jeden raz.

7.2. Słabe strony i ograniczenia

- **Pewne siebie błędy na bardzo ciemnych zdjęciach.** Część pomyłek ma pewność bliską 100% i żaden próg ich nie zatrzyma.
- **Małe piktogramy w znakach ostrzegawczych.** Przy 64×64 px model myli znaki o tym samym kształcie. Pomogłaby wyższa rozdzielczość wejścia, kosztem dłuższego treningu.

- **Odporność tylko na znane zakłócenia.** Augmentacja nie przygotowała modelu na kompresję JPEG, której nie było w treningu.
- **Klasyfikator, a nie detektor.** Model oczekuje wycinka ze znakiem na środku. Na całym kadrze z tłem rozpoznał STOP jako „zakaz wjazdu" z pewnością 95,5%, a po przycięciu do znaku poprawnie, z pewnością 99,9%. W prawdziwym systemie potrzebny byłby dodatkowo detektor znaków.
- **Zdjęcia, a nie rysunki.** Wzorcowe piktogramy znaków (rysunki na białym tle) model rozpoznaje poprawnie tylko w 30 na 43 przypadkach, np. STOP uznaje za „zakaz wjazdu". To klasyczne przesunięcie dziedziny: model zna tylko zdjęcia z kamery samochodowej.
- **Tylko znaki niemieckie.** Polskie znaki są bardzo podobne, ale nie identyczne (np. żółte tło znaków ostrzegawczych), więc skuteczność na polskich drogach nie jest zweryfikowana.
- **Ograniczenia metody XAI.** Mapa Grad-CAM w rozdzielczości 8×8 jest dość gruba, więc dobrze pokazuje, czy model patrzy na znak, ale nie, na który dokładnie fragment piktogramu.
- **Wybrana epoka była „szczęśliwa".** Model stracił na teście 1,25 p.p. macro-F1 względem walidacji, a na czystych danych lepszy okazał się wariant bez augmentacji. Jak pokazał E4 w KM2, dłuższy trening albo kryterium zatrzymania uwzględniające odporność dałyby prawdopodobnie lepszy model.

8. Podsumowanie projektu

Postawione w KM1 pytanie brzmiało: czy uczenie transferowe i odpowiednio dobrana augmentacja ograniczają spadek skuteczności klasyfikatora znaków drogowych na zakłóconych zdjęciach? Po trzech etapach odpowiedź jest taka:

- **augmentacja odpornościowa ogranicza ten spadek wyraźnie i trwale:** włączenie jej zmniejszyło średni spadek skuteczności na zakłóceniach mniej więcej o połowę, co potwierdziło się na zbiorze testowym,
- **uczenie transferowe poprawia głównie skuteczność na czystych danych** i przyspiesza trening, ale samo w sobie nie daje odporności,
- **odporność obejmuje głównie zakłócenia, które model widział w treningu**, a na nowe (JPEG) przenosi się w niewielkim stopniu.

Hipoteza	Wynik na walidacji (KM2)	Weryfikacja na teście (KM3)
H1 uczenie transferowe	potwierdzona	nieweryfikowana, bo modele uczone od zera nie były oceniane na teście

Hipoteza	Wynik na walidacji (KM2)	Weryfikacja na teście (KM3)
H2 augmentacja odpornościowa	potwierdzona	potwierdzona: mCA +5,8 p.p., koszt na czystych danych 0,6 p.p.
H3 MobileNet bliski ResNetowi	odrzucona	bez zmian, MobileNet nie był oceniany na teście
H4 odporność na niewidziany JPEG	raczej odrzucona	potwierdzona obserwacja: zysk tylko 0,4 p.p. względem A0

Finalny system to pretrenowany ResNet18 z augmentacją A2, który rozpoznaje 99,1% zdjęć testowych i 92,7% zdjęć zakłóconych, sygnalizuje niepewność w przypadkach, w których najczęściej się myli, i pozwala zobaczyć, na co patrzył przy podejmowaniu decyzji.

Największym wnioskiem dla mnie jest to, że w tym projekcie więcej dało przemyślenie danych niż wybór architektury. Prosta sieć z dobrą augmentacją okazała się bardziej odporna niż 38 razy większy pretrenowany ResNet bez niej, a decyzje podjęte na etapie analizy danych (podział po seriach, brak odbić lustrzanych, dobór siły augmentacji) okazały się kluczowe dla wiarygodności wyników.

Bibliografia

1. R. R. Selvaraju i in., *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization*, ICCV 2017. arXiv:1610.02391
2. C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, *On Calibration of Modern Neural Networks*, ICML 2017. arXiv:1706.04599
3. J. Stallkamp, M. Schlipsing, J. Salmen, C. Igel, *The German Traffic Sign Recognition Benchmark: A multi-class classification competition*, IJCNN 2011. PDF
4. D. Hendrycks, T. Dietterich, *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations*, ICLR 2019. arXiv:1903.12261